LingBot-VLA 2.0 SFT 训练加速：Teacher 离线缓存

8 张 RTX Pro 5000 · Distributed Muon · 监督微调（SFT）· 分支 `teacher-cache-on-main`（基于官方 `be969b8`）

> 把三个冻结 teacher 模型的输出预先算好存到磁盘，训练时直接读取，平均完整步时从 **4.5087 秒**降到 **3.9745 秒**，吞吐提升 **13.4%**。省下的 0.534 秒等于每步 teacher 前向的耗时（0.540 秒）。缓存的 target 与在线计算逐位一致，显存峰值下降约 5.8 GiB。功能默认关闭，不加参数时训练行为不变。

性能结果

配置	第一次（秒）	第二次（秒）	平均步时（秒）	吞吐（样本/秒）	相对基线吞吐	显存峰值（MiB）
官方代码基线	4.5082	4.5092	4.5087	56.78	—	71,799
Teacher 离线缓存	3.9757	3.9732	3.9745	64.41	+13.44%	65,867

吞吐 = 256 ÷ 平均步时；提升 = 基线步时 ÷ 优化步时 − 1。步时降低 11.85%。运行顺序为基线、缓存、缓存、基线；单次运行的步时变异系数 0.11%–0.24%。步时包含取数据的时间；省下的 0.534 秒与 teacher 耗时只差约 6 ms，说明读取缓存基本没有带来额外等待。

测试条件

项目	设置
硬件与数据	8 张 RTX Pro 5000；RoboTwin 2.0 clean 50 任务，按官方 RoboTwin pi0 流程转换的图像数据（2,500 条 episode，549,787 帧）
批量与优化器	micro batch 32；梯度累积 1；global batch 256；Distributed Muon；激活检查点；FSDP 前向后参数驻留
NCCL 与环境	`NCCL_MIN_CTAS=8`、`NCCL_NTHREADS=128`、`NCCL_P2P_READ_ENABLE=1`；RDMA 可用；PyTorch 2.8.0+cu128、NCCL 2.27.3；每个 rank 绑定 GPU 所在 NUMA 节点
测量	每次 31 步，第 1–10 步预热，统计第 11–30 步；每步从取数据前到打完日志，两端 CUDA 同步，取 8 个 rank 的最大值。GPU 降到 40°C 以下再开始，最高 64°C，无降频，功耗上限 350 W
缓存位置	本地 NVMe RAID

方法

每个训练步开头，深度 teacher（MoGe2 → MoRGBD）和 DINO 视频 teacher 对每个样本做 5 次前向，生成 4 个对齐 target。teacher 冻结、图像增强关闭、未来帧偏移固定，所以 target 只取决于样本本身，可以对整个数据集预先算一遍。

参数	作用
`--train.teacher_cache_dir DIR --train.teacher_cache_mode build`	对每个样本运行一次 teacher，写入 DIR 后退出；中断后可续算
`--train.teacher_cache_dir DIR`（read，默认）	从 DIR 读取 target 训练，不加载 teacher
`--train.teacher_cache_dir DIR --train.teacher_cache_mode verify`	照常运行 teacher，记录与缓存的差异，用缓存的 target 训练

- **存储**：每种 target 一个 bf16 内存映射文件，按样本编号索引，每个样本 1.5 MB。未来帧深度不单独存，直接读 49 帧之后那一行的当前帧深度。
- **校验**：缓存记录数据集列表和帧数、相机顺序、teacher 权重和未来帧偏移，与训练配置不一致时拒绝读取。
- **改动范围**：一个 commit，3 个文件（新增 `teacher_cache.py`，修改 `multi_vla_dataset.py` 和 `train_lingbotvla.py`），不改模型结构和训练目标。

数值验证

- **target 逐位一致**：verify 模式下，31 步里每一步 4 个 target（当前帧深度、未来帧深度、DINO 当前帧、DINO 未来帧）与在线 teacher 计算的结果全部逐元素相同（124/124）。
- **verify 模式 loss 与基线一致**：第 1 步五项 loss 逐位相同；第 1–30 步总 loss 逐步相对差平均 0.20%–0.26%，同一代码两次基线之间为 0.14%。
- **read 模式**：第 1 步三个对齐 loss 与基线逐位相同，说明数据和 target 一致；VLA loss 不同，是因为不加载 teacher 时少消耗了随机数，flow matching 的噪声序列随之改变，相当于换了随机种子。两次 read 运行之间的差异与两次基线之间相同（总 loss 平均 0.17%）。此前在另一份数据上跑 500 步，verify 模式与在线运行的 loss 相差 0.72%，最后 50 步平均 0.0506 对 0.0504。
- 本结果是短测加此前 500 步的对比，没有验证完整训练的收敛。

成本与部署

- **预计算**：8 卡共 58 分钟，瓶颈在 CPU 解码 PNG 图像（每卡 24 个 DataLoader worker，约 23 样本/秒/卡）。数据和 teacher 不变时缓存可以反复使用；按每步省 0.534 秒计算，约 6,500 步即可抵消预计算时间。
- **磁盘**：806 GiB（1.5 MB × 帧数）。缓存大小和帧数成正比，和图像分辨率无关。
- **读取需求**：每卡每步读 32 × 2 MB，8 卡合计约 130 MB/s，由 DataLoader 后台预取。此前测试中，清空 page cache 后从 NVMe 冷读，以及把读取限速到云盘 ESSD PL1 / PL0 的上限（350 / 180 MB/s），步时都没有变化。
- **限制**：打开图像增强，或更换数据集、teacher 权重、相机顺序后，需要重建缓存。